


Федеральное государственное автономное образовательное учреждение высшего образования
«Санкт-Петербургский политехнический университет Петра Великого»
Институт компьютерных наук и кибербезопасности
Программная инженерия



Отчет по курсовой работе
по дисциплине «Конструирование программного обеспечения»
на тему «**Инструмент коллаборативного автоматизированного перевода
(САТ-программа)**»

Руководитель

Юркин В. А.

Оглавление

Оглавление.....	2
Woofie.....	3
Участники проекта.....	3
Технологический стек.....	3
Определение проблемы.....	3
Основные требования.....	4
Разработка архитектуры и детальное проектирование.....	4
Характер нагрузки.....	4
API.....	5
1. Работа с текстом.....	5
GET /translations.....	5
POST /translations-fetch-updates.....	5
POST /translations.....	6
GET /translations/{id}.....	7
PUT /translations/{id}.....	7
DELETE /translations/{id}.....	8
2. Работа с глоссарием.....	8
GET /glossary.....	8
POST /glossary-fetch-updates.....	9
POST /glossary.....	9
GET /glossary/{id}.....	10
PUT /glossary/{id}.....	10
DELETE /glossary/{id}.....	10
3. Машинный перевод.....	11
GET /translation-services.....	11
POST /translate/{id}.....	11
Демонстрация работы.....	12
Тестирование.....	12
Тестирование с нагрузкой.....	18
Сборка и запуск.....	20

Woofie

Инструмент коллаборативного автоматизированного перевода (CAT-программа)

GitHub Репозиторий Woofie: <https://github.com/odintsovks/Woofie>

GitHub Репозиторий Woofie-Server: <https://github.com/odintsovks/Woofie-Server>

GitHub Репозиторий Woofie-Client: <https://github.com/odintsovks/Woofie-Client>

Участники проекта

Одинцов Кирилл Сергеевич (гр. 5130904/30106)

Дмитриев Арсений Эдуардович (гр. 5130904/30106)

Засульский Егор Андреевич (гр. 5130904/30106)

Маланьин Никита Александрович (гр. 5130904/30106)

Проселков Станислав Павлович (гр. 5130904/30106)

Горбунова Алена Евгеньевна (гр. 5130904/30106)

Технологический стек

- Серверная часть: Java Spring Framework
- Базы данных: PostgreSQL
- Внешние зависимости: интеграция с сервисами машинного перевода (к примеру «Яндекс.Переводчик» с использованием API-ключа)
- UI: Qt 6

Определение проблемы

Отсутствие открытых CAT-программ позволяющих организовывать проекты в виде дерева. Вместо этого существующие инструменты ограничиваются табличным отображением единиц перевода, что усложняет процесс, когда последовательность текста зависит от конкретных условий (к примеру «деревья диалогов» в видеоиграх).

Основные требования

- Возможность использования древовидной структуры для отображения единиц перевода.

Когда на практике переводимый текст зависит от строго заданных условий, я хочу иметь возможность отражать это структурой единиц перевода в САТ-программе, чтобы не путаться в исключительно последовательном табличном отображении

- Возможность делать запросы в сервисы машинного перевода и проверки правописания.

Когда возникает необходимость сверить смысл или правописание, я хочу использовать быстродоступные сервисы машинного перевода и правописания, чтобы не выбиваться из процесса перевода.

- Возможность редактировать единицы перевода в режиме реального времени.

Когда другой пользователь тем или иным образом изменил единицу перевода, я хочу увидеть это изменение без нужды ручного обновления, чтобы всегда видеть актуальное состояние проекта.

Ожидается, что данным набором инструментов (клиентом и сервером) будут пользоваться команды переводчиков текста, которые обычно являются небольшими, но программы строятся с расчётом на максимум 10к пользователей в сутки. Как правило проекты завершаются меньше, чем за год, период хранения информации соответствующий.

Разработка архитектуры и детальное проектирование

Характер нагрузки

- R/W нагрузка - ожидается более высокая интенсивность чтения. При работе с текстом программа-клиент будет активно производить операции вставки в базу данных, но при этом текст должен автоматически синхронизироваться между всеми клиентами, таким образом чтение каждого нового изменения в базу данных растёт с количеством пользователей.
- Объём трафика - подавляюще большую часть трафика будут занимать текстовые данные единиц перевода, оценить объём можно следующим образом:
 - Одну единицу перевода можно оценить в 1 КиБ (достаточно примерно на 1024 / 2 байта на символ / 4 букв на слово = 128 слов в кодировке UTF-8), один пользователь за рабочую неделю сделает примерно 500 изменений в текст (40 часов * 60 / 5 минут на изменение = 480 изменений) изменений в текст, соответственно количество данных на запись оценивается в $1 \text{ КиБ} * 500 / 7 = 72 \text{ КиБ}$ на пользователя в день. При этом количество данных на чтение дополнительно растёт с количеством пользователей, т.к. каждый пользователь должен иметь доступ к истории изменений.
 - Запись:
 - Типовой случай: $72 \text{ КиБ/день} * 100 \text{ пользователей} = 7200 \text{ КиБ/день} = 7 \text{ МиБ/день}$
 - Худший случай: $72 \text{ КиБ/день} * 10000 \text{ пользователей} = 720000 \text{ КиБ/день} = 700 \text{ МиБ/день}$
 - Чтение:
 - Типовой случай: $7 \text{ МиБ/день} * 100 \text{ пользователей} = 700 \text{ МиБ/день}$
 - Худший случай: $7 \text{ МиБ/день} * 10000 \text{ пользователей} = 70000 \text{ МиБ/день} = 70 \text{ ГиБ/день}$

- На практике количество данных на запись/чтение будет ограничено сверху количеством единиц перевода.
- Объёмы дисковой системы - как в случае с объёмом трафика, большую часть дискового пространства будут занимать текстовые данные; в зависимости от размера проекта количество единиц перевода может превышать десятки, если не сотни тысяч. Как правило одна единица требует не больше двух-трёх итераций (черновой вариант + вычитка), соответственно:
 - Типовой случай: 1 КиБ/ед.п. * 10000 ед.п. * 3 итерации = 30000 КиБ = 29 МиБ
 - Худший случай: 1 КиБ/ед.п. * 100000 ед.п. * 3 итерации = 300000 КиБ = 293 МиБ

API

1. Работа с текстом

GET /translations

Описание: запрос всех единиц перевода (пар "оригинал-перевод")

- Статус: 200 OK
 - Тело:


```
{
  "timestamp": 0,
  "translations": [
    {
      "id": "",
      "sourceText": "",
      "targetText": "",
      "connections": [
        {
          "id": "",
          "description": ""
        },
        // ...
      ]
    },
    // ...
  ]
}
```

Требования по максимальному времени отклика: 5 секунд (запрос производится при запуске клиента, ожидаем что формирование запроса может быть медленным, а время отклика не критично на этапе инициализации программы).

POST /translations-fetch-updates

Описание: запрос обновлённых единиц перевода с определённой отметки времени

- Тело запроса:


```
{
  "timestamp": 0
}
```
- Статус: 200 OK

- Тело:


```
[
{
  "id": "",
  "sourceText": "",
  "targetText": "",
  "connections": [
    {
      "id": "",
      "description": ""
    },
    // ...
  ]
},
// ...
]
```

- Статус: *400 Bad Request*
 - Неправильно сформирован запрос; отсутствует поле *timestamp*

Требования по максимальному времени отклика: 1 секунда (ожидается, что программа будет запрашивать свежие обновления текстовых данных раз в 1-2 секунды)

POST /translations

Описание: добавить единицу перевода

- Тело запроса:


```
{
  "sourceText": "",
  "targetText": "",
  "connections": [
    {
      "id": "",
      "description": ""
    },
    // ...
  ]
}
```

- Статус: *201 Created*
 - Тело:

```

{
  "id": "",
  "sourceText": "",
  "targetText": "",
  "connections": [
    {
      "id": "",
      "description": ""
    },
    // ...
  ]
}

```

- Статус: *400 Bad Request*
 - Неправильно сформирован запрос; отсутствует одно из полей

GET /translations/{id}

Описание: запросить единицу перевода по заданному индексу

Статус: *200 OK*

- Тело:


```

{
  "sourceText": "",
  "targetText": "",
  "connections": [
    {
      "id": "",
      "description": ""
    },
    // ...
  ]
}

```

• Статус: *404 Not Found*

- Единицы перевода не существует по заданному индексу

PUT /translations/{id}

Описание: установить значения единицы перевода по заданному индексу (добавить если не существует)

- Тело запроса:


```

{
  "sourceText": "",
  "targetText": "",
  "connections": [
    {
      "id": "",

```

```

        "description": ""
    },
    // ...
]
}

```

- Статус: *200 OK* и *201 Created*

- Тело


```

      {
        "id": "",
        "sourceText": "",
        "targetText": "",
        "connections": [
          {
            "id": "",
            "description": ""
          },
          // ...
        ]
      }
      
```

- Статус: *400 Bad Request*

- Неправильно сформирован запрос; отсутствует одно из полей.

DELETE /translations/{id}

Описание: удалить единицу перевода по заданному индексу

- Статус: *204 No Content*
- Статус: *404 Not Found*
 - Единицы перевода не существовало по заданному индексу перед запросом на удаление

2. Работа с глоссарием

GET /glossary

Описание: запрос списка записей глоссария

- Статус: *200 OK*
 - Тело:


```

          {
            "timestamp": 0,
            "entries": [
              {
                "id": "",
                "targetTerm": "",
                "sourceTerm": "",
                "definition": ""
              },
              // ...
            ]
          }
          
```



```

    // ...
  ]
}

```

Требования по максимальному времени отклика: 5 секунда (аналогично с GET /translations)

POST /glossary-fetch-updates

Описание: запрос обновлённых записей глоссария с определённой отметки времени

- Тело запроса:

```

{
  "timestamp": 0
}

```

- Статус: *200 OK*

Тело:

```

[
  {
    "id": "",
    "targetTerm": "",
    "sourceTerm": "",
    "definition": ""
  },
  // ...
]

```

- Статус: *400 Bad Request*
 - Неправильно сформирован запрос; отсутствует поле *timestamp*

Требования по максимальному времени отклика: 5 секунд (аналогично с GET /translations-fetch-updates, но ожидаем, что обновления глоссария запрашиваются реже).

POST /glossary

Описание: добавить запись в глоссарий.

- Тело запроса:

```

{
  "targetTerm": "",
  "sourceTerm": "",
  "definition": ""
}

```

- Статус: *201 Created*

- Тело:


```

      {
        "id": "",

```

```

    "targetTerm": "",
    "sourceTerm": "",
    "definition": ""
  }

```

- Статус: *400 Bad Request*

- Неправильно сформирован запрос; отсутствует одно из полей.

GET /glossary/{id}

Описание: запросить запись из глоссария по индексу

- Статус: *200 OK*

- Тело:

```

{
  "targetTerm": "",
  "sourceTerm": "",
  "definition": ""
}

```

- Статус: *404 Not Found*

- Записи глоссария не существует по заданному индексу

PUT /glossary/{id}

Описание: изменить запись глоссария по индексу (добавить если не существует)

- Тело запроса:

```

{
  "targetTerm": "",
  "sourceTerm": "",
  "definition": ""
}

```

- Статус: *200 OK* и *201 Created*

- Тело

```

{
  "id": "",
  "targetTerm": "",
  "sourceTerm": "",
  "definition": ""
}

```

- Статус: *400 Bad Request*

- Неправильно сформирован запрос; отсутствует одно из полей.

DELETE /glossary/{id}

Описание:

- Статус: *204 No Content*
- Статус: *404 Not Found*
 - Записи глоссария не существовало по заданному индексу перед запросом на удаление

3. Машинный перевод

GET /translation-services

Описание: запросить информацию о всех доступных сервисах машинного перевода

- Статус: *200 OK*
 - Тело:


```
[
  {
    "id": "",
    "name": ""
  },
  //...
]
```

POST /translate/{id}

Описание: запросить перевод строки у сервиса машинного перевода по заданному индексу

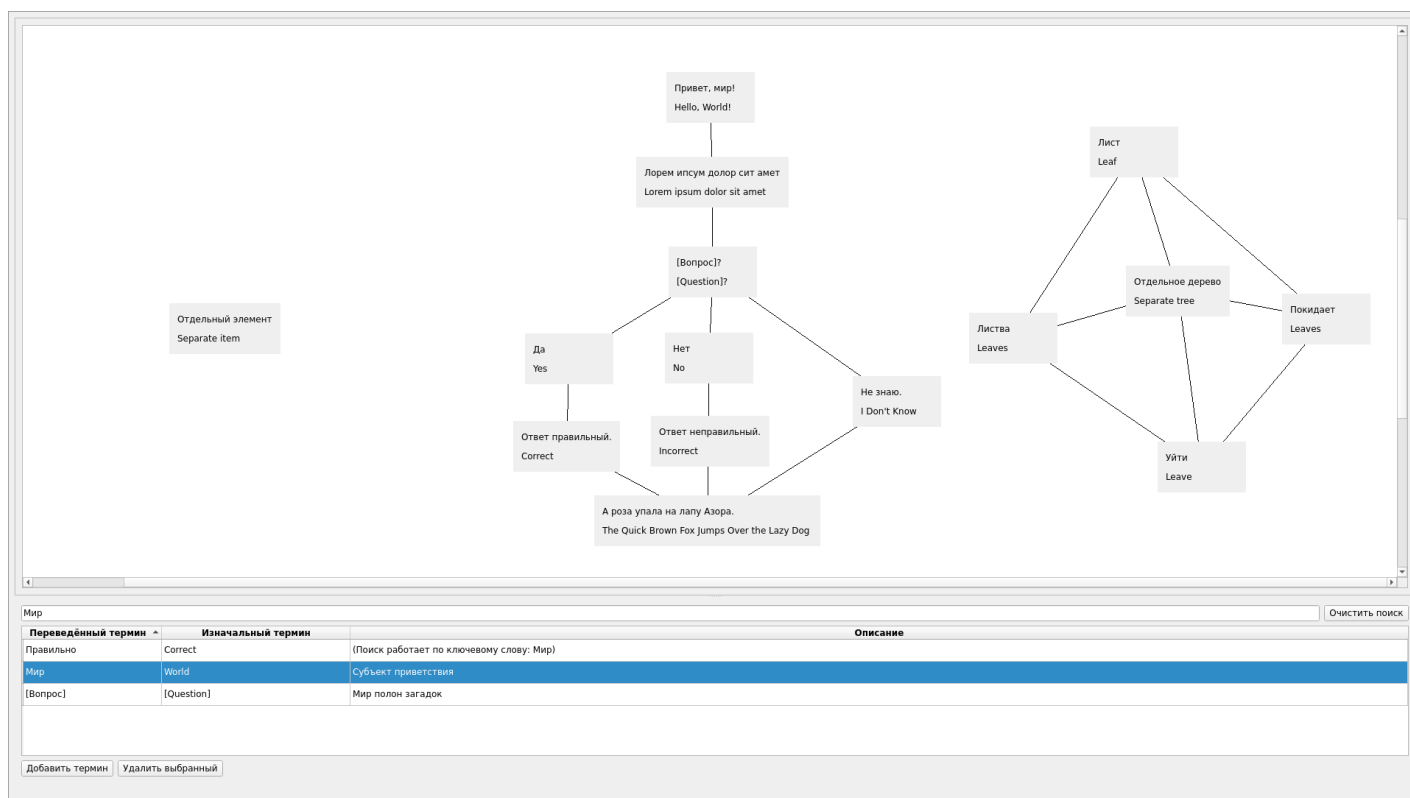
- Тело запроса:


```
{
  "text": ""
}
```
- Статус: *200 OK*
 - Тело:


```
{
  "text": ""
}
```
- Статус: *503 Service Unavailable*
 - Сервис перевода не доступен; сервер не получил ответ

Требования по максимальному времени отклика: N/a (полностью зависит от доступности и времени отклика стороннего сервиса)

Демонстрация работы



Тестирование

Тестовые запросы http к серверу:

1. GET /api/translations (Запрос всех единиц)

Ожидаемый статус: 200 OK

Ожидаемое тело: { "timestamp": ..., "translations": [...] }

GET http://localhost:8080/api/translations

2. POST /api/translations (Добавление единицы)

Ожидаемый статус: 201 Created

POST http://localhost:8080/api/translations

Content-Type: application/json

```
{  
  "sourceText": "Hello world",  
}
```

```
"targetText": "Привет мир",  
"connections": [  
  { "description": "First connection" }  
]  
}
```

3. POST /api/translations (Ошибка 400 - отсутствует поле)

Ожидаемый статус: *400 Bad Request*

POST http://localhost:8080/api/translations

Content-Type: application/json

```
{  
  "targetText": "Only target"  
}
```

4. GET /api/translations/{id} (Запрос по ID)

Ожидаемый статус: *200 OK*

GET http://localhost:8080/api/translations/2

5. DELETE /api/translations/{id} (Удаление)

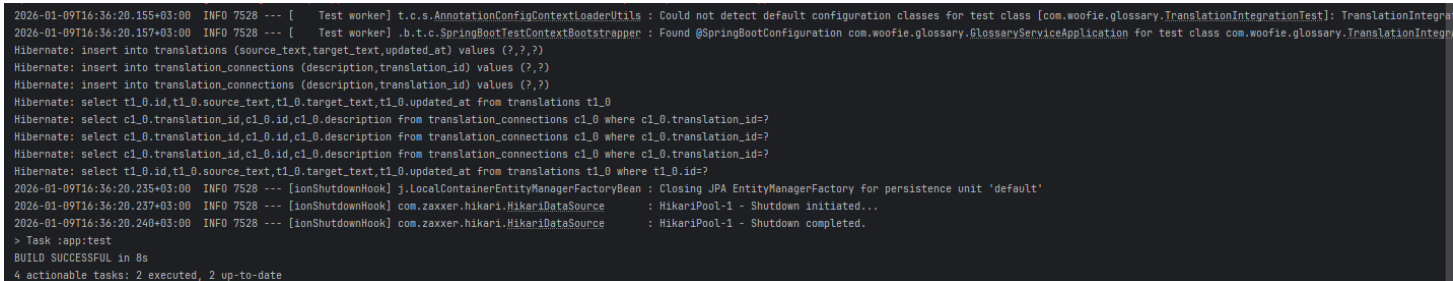
Ожидаемый статус: *204 No Content*

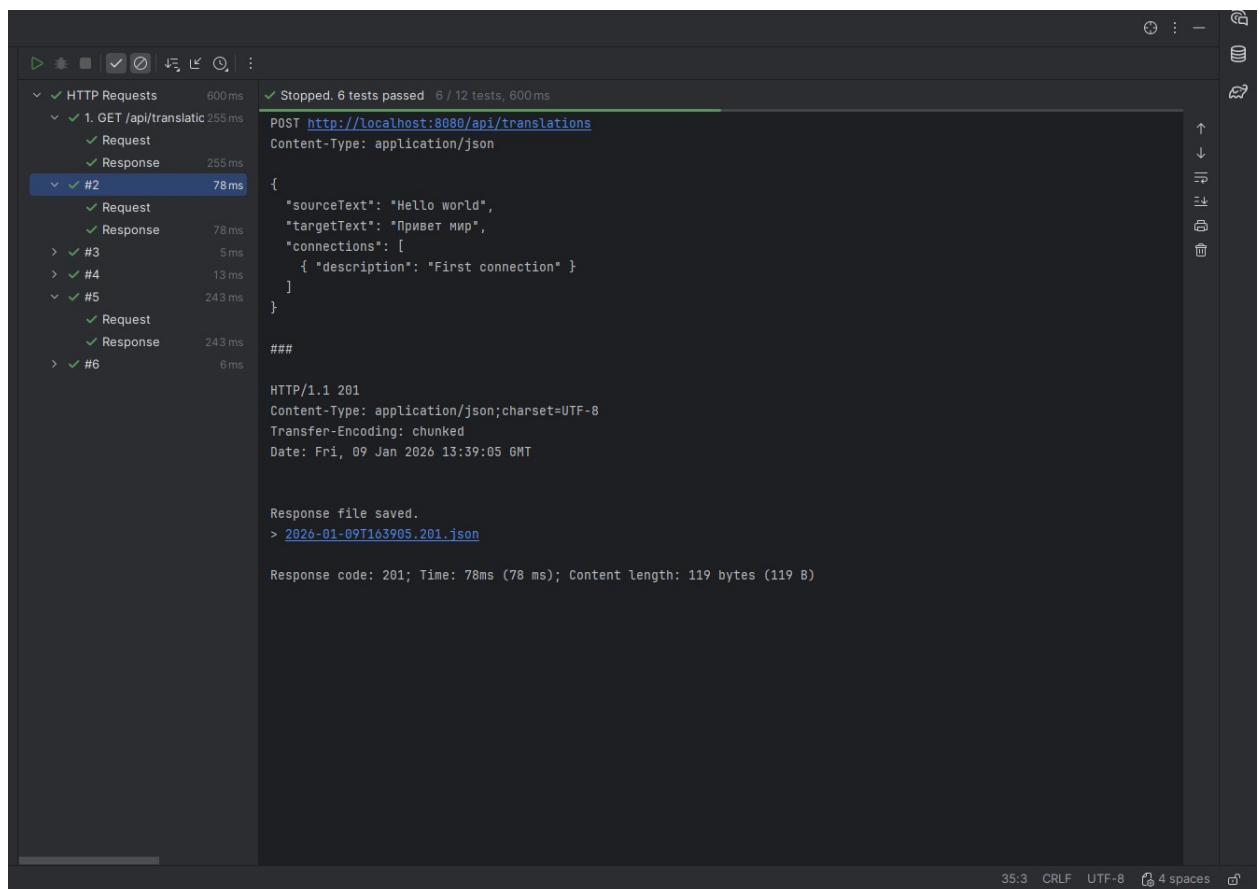
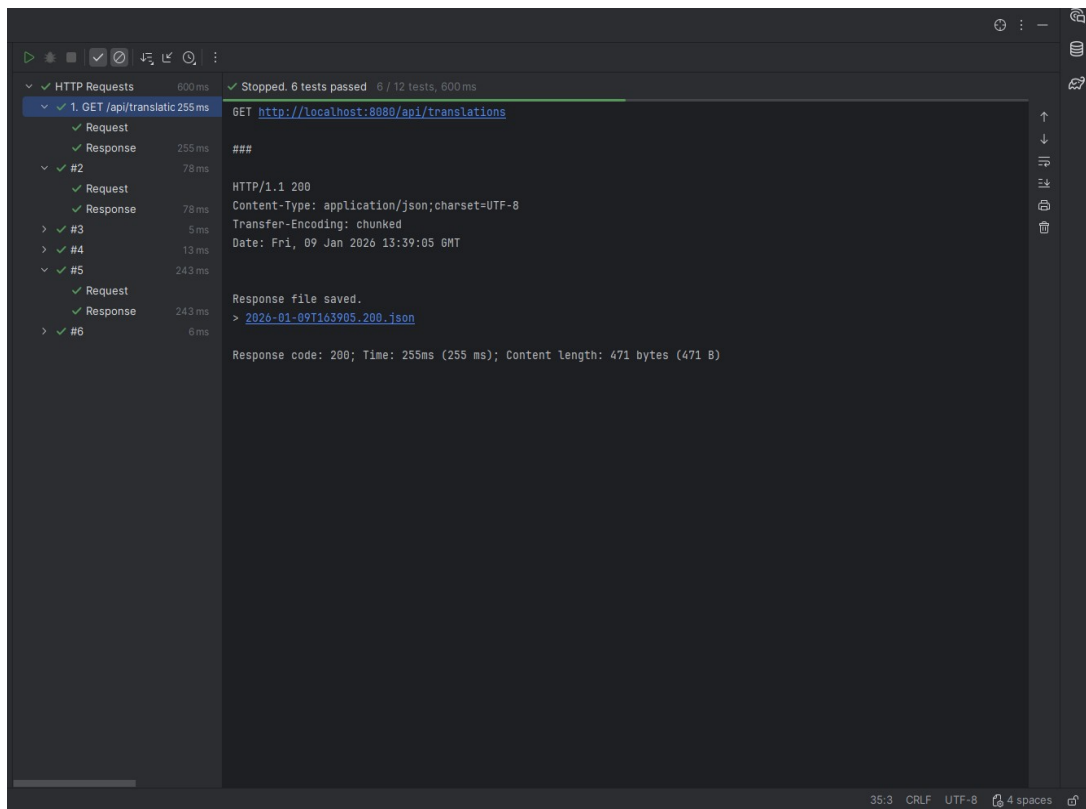
DELETE http://localhost:8080/api/translations/1

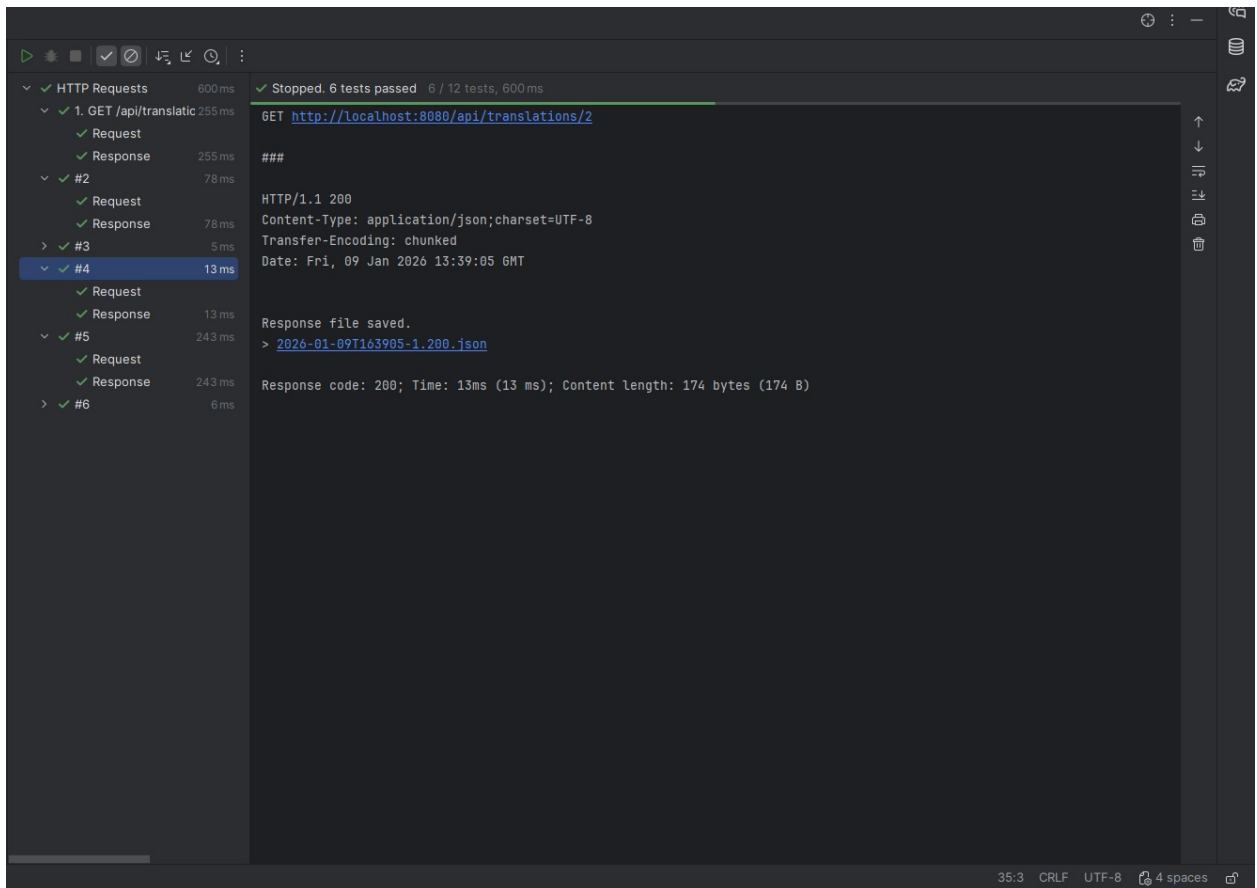
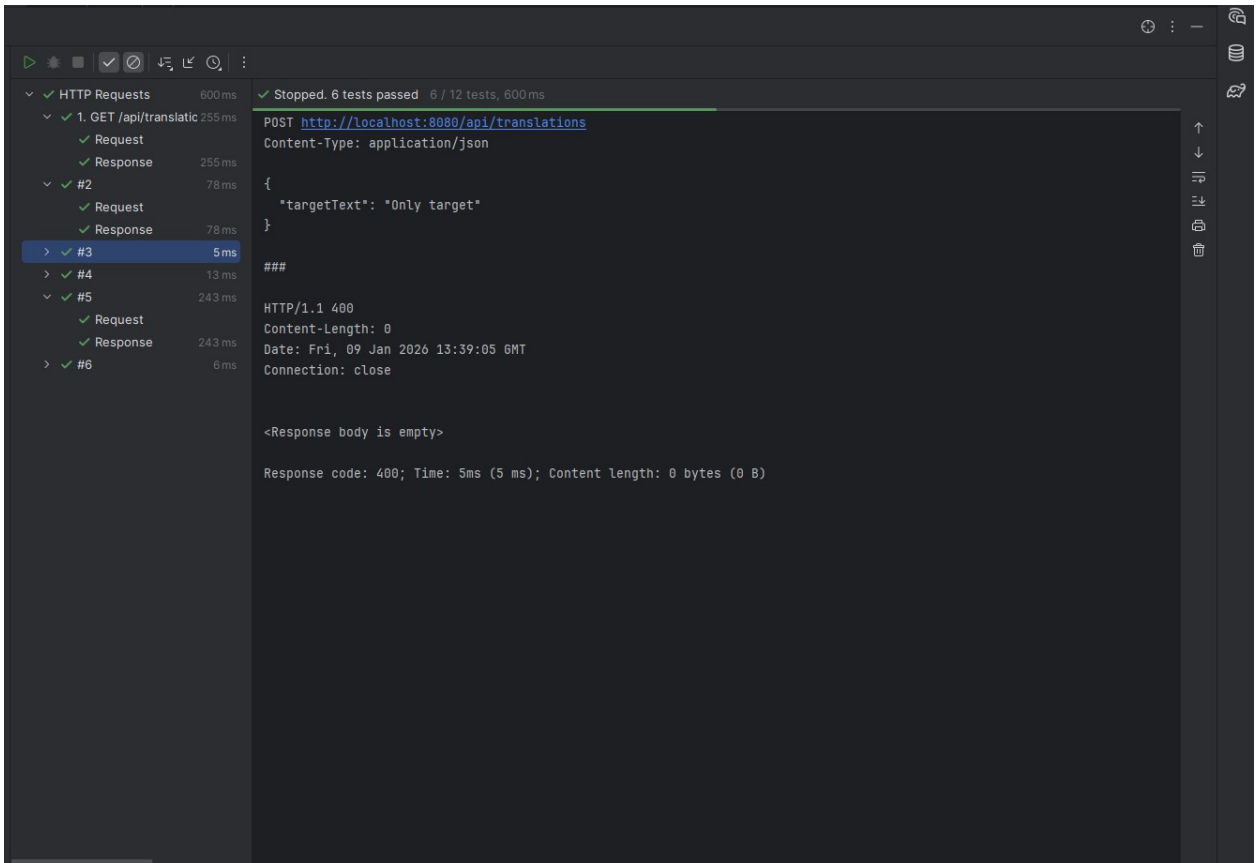
6. DELETE /api/translations/{id} (Ошибка 404 - уже удалено)

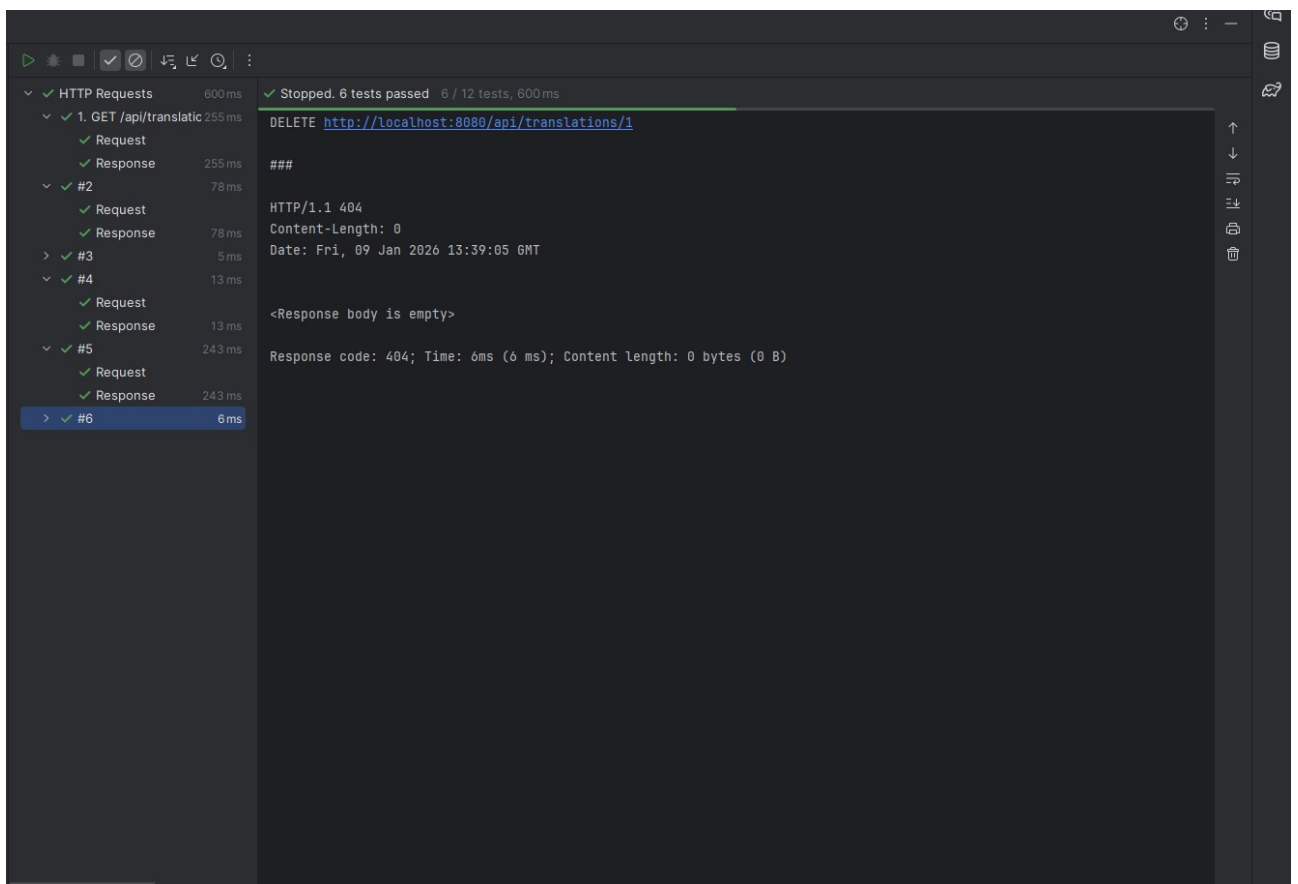
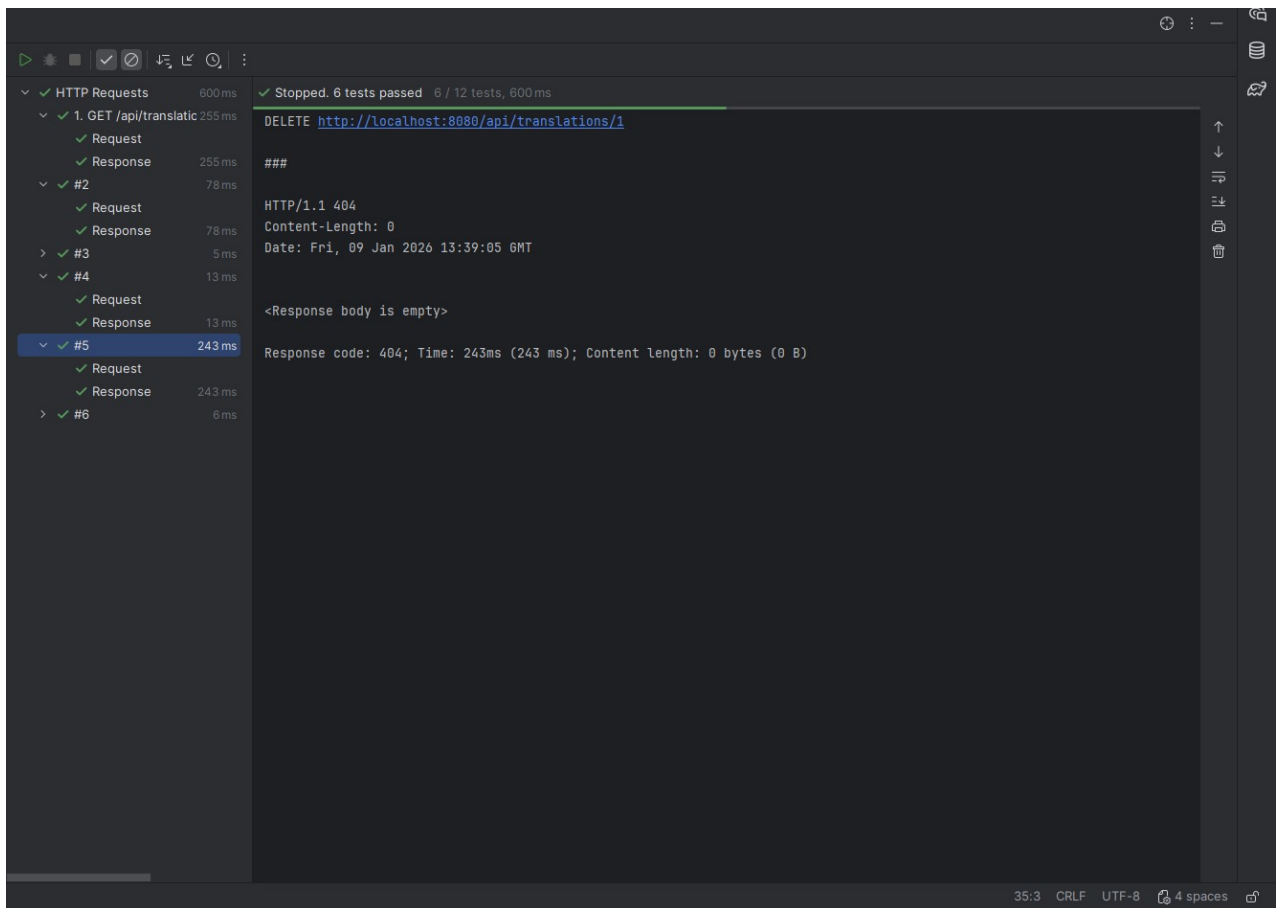
Ожидаемый статус: *404 Not Found*

DELETE http://localhost:8080/api/translations/1









Тестирование с нагрузкой

Сервер был протестирован под симулированной нагрузкой с использованием *gatling*. Испытана нагрузка на сценариях, где в течение минуты или более отправляется 1 тысяча, 5 тысяч и 10 тысяч POST-запросов на */api/translations* в секунду.

- 1к POST-запросов:

----- Global Information ----- ---Total--- ----OK---- ----KO----			
> request count	60,000	60,000	-
> min response time (ms)	0	0	-
> max response time (ms)	267	267	-
> mean response time (ms)	2	2	-
> response time std deviation (ms)	9	9	-
> response time 50th percentile (ms)	1	1	-
> response time 75th percentile (ms)	1	1	-
> response time 95th percentile (ms)	1	1	-
> response time 99th percentile (ms)	2	2	-
> mean throughput (rps)	1,000	1,000	-
----- Response Time Distribution -----			
> OK: t < 800 ms	60,000 (100%)		
> OK: 800 ms <= t < 1200 ms	0 (0%)		
> OK: t >= 1200 ms	0 (0%)		
> KO	0 (0%)		

- 5к POST-запросов:

----- Global Information ----- ---Total--- ----OK---- ----KO----			
--	--	--	--

> request count	300,000 300,000 -
> min response time (ms)	0 0 -
> max response time (ms)	5,425 5,425 -
> mean response time (ms)	162 162 -
> response time std deviation (ms)	532 532 -
> response time 50th percentile (ms)	2 2 -
> response time 75th percentile (ms)	2 2 -
> response time 95th percentile (ms)	1,322 1,323 -
> response time 99th percentile (ms)	4,223 4,240 -
> mean throughput (rps)	4,918.03 4,918.03 -

---- Response Time Distribution -----

> OK: t < 800 ms	282,126 (94.04%)
> OK: 800 ms <= t < 1200 ms	1,275 (0.43%)
> OK: t >= 1200 ms	16,599 (5.53%)
> KO	0 (0%)

- 10к POST-запросов:

---- Global Information -----|---Total---|----OK---|---KO----

> request count	600,000 268,316 331,684
> min response time (ms)	3 301 3
> max response time (ms)	91,182 82,066 91,182
> mean response time (ms)	12,042 13,366 10,971
> response time std deviation (ms)	11,173 8,861 12,639
> response time 50th percentile (ms)	9,463 11,284 7,711
> response time 75th percentile (ms)	16,419 18,420 14,489
> response time 95th percentile (ms)	29,317 29,823 28,248

```

> response time 99th percentile (ms)           | 62,624 | 39,025 | 71,010
> mean throughput (rps)                       | 4,477.61 | 2,002.36 | 2,475.25
----- Response Time Distribution -----
> OK: t < 800 ms                               1,974 (0.33%)
> OK: 800 ms <= t < 1200 ms                   2,326 (0.39%)
> OK: t >= 1200 ms                           264,016 (44%)
> KO                                           331,684 (55.28%)
----- Errors -----
> j.n.ConnectException: connect(..) failed: Cannot assign requested address      305,715
(92.17%)
> i.n.c.ConnectTimeoutException: connection timed out after 10000 ms: /127.0.0.1:8080
16,015 (4.83%)
> Request timeout to 127.0.0.1/127.0.0.1:8080 after 60000 ms                    9,943 (3%)
> j.i.IOException: Premature close                                               11 (0%)
=====
=====

```

Результаты показывают, что нагрузку в 5 тысяч запросов/с и ниже сервер выдерживает без особых трудностей, подавляющее большинство таких запросов получают ответ меньше, чем за секунду. Когда нагрузка достигает 10 тысяч запросов/с - больше половины запросов не получают ответ (92% из них отбрасывает операционная система из-за длинной очереди), а средняя скорость обработки увеличивается до 12 секунд. Учитывая, что даже 1 тысяча запросов в секунду это нереалистично высокая мерка для потенциального пользования данной программы - за её масштабируемость беспокоиться нет необходимости.

Сборка и запуск

Для сборки клиента используется утилита *cmake*:

```
cmake -S Woofie -B build
cmake --build build
```

Для упрощения сборки вне контейнера (в частности для подгрузки библиотек и среды разработки QtCreator) можно применить менеджер пакетов и утилиты *nix*:

```
nix develop
```

Предусмотрена сборка через *docker*:

```
docker build -t buildimage
```

В отличие от серверной стороны, ввиду того, что клиент является GUI-приложением, его запуск изнутри контейнера затруднён, если не невозможен.

Для ручного тестирования, сборки и запуска сервера используется *gradle*:

```
gradle test
```

```
gradle build  
gradle bootRun
```

Для ручного запуска (пустой) базы данных PostgreSQL так же применяется *nix* :
nix run

Базу данных и сервер можно собрать и запустить используя *docker-compose*
docker-compose up